

分段式拓扑后处理：一种提升无人机影像藻类分割质量的轻量级方法

吴天宇¹，刘俊辉¹，贺一冉¹，乔梓阁¹

¹ 华中科技大学人工智能与自动化学院，武汉 430074

摘要

无人机可见光影像在水体藻类分割任务中面临三类典型噪点：孤立假水体、水域内部假岸碎片、以及岸边像素的误分类。针对这些问题，本文提出一种三步拓扑后处理流水线，在不改变分割模型结构的前提下显著提升分割质量。第一步通过连通域分析保留最大水域，消除被岸包围的孤立假水体（岸拓扑修复）；第二步填充被水域完全包围且面积不超过 5000 px^2 的小岸碎片（水拓扑修复）；第三步引入岸水二分模型（mIoU 0.977）对残留的水中岸像素进行像素级语义修正。在 54 张无人机标注数据上的消融实验表明，三步后处理逐级提升分割质量，其中 Shore IoU 提升 +5.3% ($0.8450 \rightarrow 0.8899$)，全开配置 mIoU 达 0.7237。定性分析进一步验证了各步骤在完整正射校正图和困难样本上的有效性。该方法的设计遵循“拓扑负责结构，语义负责像素判别”的解耦原则，可推广至其他基于分割的水体分析任务。

关键词：语义分割后处理；拓扑修复；连通域分析；藻类监测；无人机影像

1 引言

淡水藻类水华是全球性水环境问题，准确监测藻类的空间分布和时序变化对水质管理和生态预警至关重要。无人机搭载可见光相机以 5–10 cm 的地面分辨率对目标水域进行近地观测，填补了卫星遥感（10 m）和人工采样之间的空间尺度空缺。基于深度学习的语义分割方法能够从无人机影像中自动提取岸、水、水生植物和藻类四类区域，为后续藻类生物量估算和生长预测提供像素级空间信息 [1, 2]。

然而，分割模型在实际部署中面临三类典型噪声输出。第一类是**孤立假水体**——模型将岸边阴影、湿润土壤或深色植被误判为水域，这些假水域与主体水域不连通，在物理上不可能存在。第二类是**水中假岸碎片**——水面反光、漂浮物或模型对岸边特征的过度泛化导致水域内部被错误标记为岸像素，形成被水体包围的“假岛屿”。第三类是**岸边语义混淆**——悬空树冠遮挡、水岸交界的混合像素使得模型在岸/水二分类上反复出错。

传统应对方案主要依赖数据驱动：增加标注量、更强的数据增强或更大的模型来“硬抗”噪声 [3]。但无人机影像的像素级标注成本高（每张 5–10 分钟），且数量有限（本

研究仅 54 张)。基于图模型的后处理方法如全连接条件随机场 (DenseCRF) 专注于边界平滑, 无法处理需要全局拓扑信息的结构性错误 (如孤立水域的消除) [4]。更为关键的是, 这三类噪声分别涉及拓扑连通性、几何形态和语义判别三个不同层次, 单一操作难以同时解决。

本文提出一种轻量级三步后处理流水线, 在不重新训练分割模型的前提下逐级消除三类噪点: (1) 岸拓扑修复通过连通域分析保留最大水域、消除孤立假水体; (2) 水拓扑修复填充被水域包围且面积不超过阈值的小型假岸碎片; (3) 岸水二分模型对前两步残留的水中岸像素进行像素级语义修正 (该二分模型 mIoU 达 0.977)。三步设计遵循“拓扑负责结构, 语义负责像素判别”的解耦原则, 各步骤有明确的处理目标且互不越界。

本文的主要贡献包括: (1) 提出三步解耦后处理流水线, 将分割后处理系统性地分解为拓扑、几何、语义三个层次; (2) 引入岸水二分模型作为分割模型的互补判别器, 利用“二分类信息优势”修正四分类模型的像素级误判; (3) 通过消融实验和定性分析逐级验证每一步的有效性, 为同类后处理方法设计提供参考。

1.1 相关工作

基于深度学习的语义分割在遥感影像分析中取得了显著进展。DeepLabV3+ 通过空洞空间金字塔池化和编码器-解码器结构实现了多尺度上下文融合 [1]; ConvNeXt 通过现代化卷积设计在 ImageNet 分类和下游分割任务上达到了与 Transformer 相当的性能 [2]。然而, 这些模型在无人机水体场景中的输出仍包含结构性噪声, 后处理成为必要的补充环节。

DenseCRF 通过在全连接图上优化吉布斯能量函数来细化分割边界, 但其成对势函数仅建模相邻像素的颜色和空间相似性, 无法修正孤立连通域这类需要非局部拓扑信息的错误 [4]。形态学操作 (开运算、闭运算) 虽然能消除孤立噪点, 但感受野受限与结构元素大小, 无法区分“被岸包围的假水域”和“真实小水塘”。本文的方法与这些工作互补: 拓扑修复处理连通域级别的结构错误, 二分模型提供像素级语义校准, 两者分工明确。

2 方法

2.1 整体框架

本文提出的后处理流水线作用于分割模型输出之后、下游分析模块之前, 由三个顺序执行的步骤构成:

$$\mathbf{P}_{\text{final}} = \Phi_{\text{bin}} \circ \Phi_{\text{water}} \circ \Phi_{\text{shore}}(\mathbf{P}_{\text{raw}}) \quad (1)$$

其中 $\mathbf{P}_{\text{raw}} \in \{0, 1, 2, 3\}^{H \times W}$ 为分割模型的原始输出 (0= 岸, 1= 水, 2= 水生植物, 3= 藻类)。三个函数依次为岸拓扑修复 Φ_{shore} 、水拓扑修复 Φ_{water} 和二分语义修正 Φ_{bin} 。

执行顺序固定不可变更，因为每个后续步骤都依赖前一步消除对应级别的噪声后才能正确运作。

2.2 Step 1: 岸拓扑修复

第一步解决孤立假水体问题——被岸像素完全包围、与主体水域不连通的小块水域。这类噪点具有明确的拓扑特征（与主体水域隔断），但无法通过局部操作区分（形状和大小可能与其实小水塘无异）。

算法流程如 Algorithm 1 所示。对分割掩码中的非岸像素集合进行 4-连通域标记，保留面积最大的连通域作为主体水域，其余所有水域连通域强制转换为岸：

$$\Phi_{\text{shore}}(\mathbf{P})[x, y] = \begin{cases} 0, & L[x, y] \neq L_{\max} \text{ and } \mathbf{P}[x, y] \neq 0 \\ \mathbf{P}[x, y], & \text{otherwise} \end{cases} \quad (2)$$

式中 L 为非岸像素的连通域标签图， $L_{\max}$ 为像素数最多的标签。该操作是一个硬编码的拓扑约束——无论分割模型以多大置信度将某区域判为水域，只要不与主体水域连通，在水文学角度就不可能成立。 Φ_{shore} 不修改主体水域内部的任何像素，仅消除外部孤立噪点。

Algorithm 1 岸拓扑修复 Φ_{shore}

```

1: non_shore  $\leftarrow (\mathbf{P} \neq 0)$ 
2: labeled,  $n \leftarrow \text{connected\_components}(\text{non\_shore})$ 
3: if  $n \leq 1$  then return  $\mathbf{P}$ 
4: end if
5: sizes[ $i$ ]  $\leftarrow \sum[\text{labeled} = i], \forall i \in \{1, \dots, n\}$ 
6:  $L_{\max} \leftarrow \arg \max_i \text{sizes}[i]$ 
7: for  $i \leftarrow 1$  to  $n$  do
8:   if  $i \neq L_{\max}$  then
9:      $\mathbf{P}[\text{labeled} = i] \leftarrow 0$ 
10:  end if
11: end for
12: return  $\mathbf{P}$ 

```

2.3 Step 2: 水拓扑修复

第二步解决水中假岸碎片——被水域（类别 1/2/3）完全包围的小块岸像素群。关键挑战在于区分“应被填充的假岸碎片”和“应保留的真实陆岛”。

检测条件：对类别 0 的每个连通域 C ，判定为待填充碎片需同时满足：（1）面积 $|C| \leq \tau_{\max}$ （默认 5000 px²），排除真实陆岛；（2）对 C 进行结构元素膨胀后的边界像素

全部属于水域集合（完全包围检测）；（3）膨胀边界不与外接岸像素相连（排除半岛）。

条件（1）的面积阈值 $\tau_{\max}$ 是经验参数，对应约 5 cm GSD 下 12.5 m² 的物理面积——小于此面积的水中”岸”在池塘场景中极大概率是噪点而非真实岛屿。

填充策略：对检测到的待填充碎片，统计其膨胀边界在原始掩码中的类别分布，以多数类投票决定填充值。与全局填充为”水”的简单策略不同，多数类投票利用了碎片周围的局部水域上下文——靠近藻类的碎片可能填充为藻类，靠近水草的区域可能填充为水生植物。实现中使用 `scipy.ndimage.find_objects` 限制分析至连通域的包围盒，避免全图扫描。

$$\Phi_{\text{water}}(\mathbf{P})[x, y] = \begin{cases} \text{mode}(\mathbf{P}[B_C]), & (x, y) \in C, |C| \leq \tau_{\max}, \text{surrounded}(C) \\ \mathbf{P}[x, y], & \text{otherwise} \end{cases} \quad (3)$$

式中 $B_C = \text{dilate}(C) \setminus C$ 为膨胀边界， $\text{surrounded}(C)$ 表示 B_C 中所有像素均属于水域。

2.4 Step 3: 二分语义修正

第三步处理前两步后仍残留的水中岸像素。这些残留可能包括：（1）面积超过 $\tau_{\max}$ 的真实岛屿但部分像素被四类模型误判为岸；（2）在复杂边界处四类模型反复出错的像素。

二分模型：训练一个岸水二分类模型（DeepLabV3+ ConvNeXt-Tiny, 2 分类, mIoU 0.977），与四类分割模型共享训练数据但标签自动映射（岸 $\rightarrow 0$, 水 + 水草 + 藻类 $\rightarrow 1$ ）。二分模型的角色是提供与四类分割模型互补的语义判断——在”这个像素是岸还是水”这一问题上，二分类器的判别能力（mIoU 0.977）理论上强于四分类器对岸类别的判别（Shore IoU ≈ 0.85 ）。

执行流程：（1）检测 $\Phi_{\text{water}}(\mathbf{P})$ 中残留的、被水域完全包围的岸连通域；（2）对每个水中岸连通域 C ，使用二分模型在该区域内推理，计算水域像素比例 r_C ；（3）若 $r_C > 0.5$ ，二分模型认为该区域是水域 $\rightarrow$ 用多数类投票填充；（4）若 $r_C \leq 0.5$ ，二分模型认为该区域是岸 $\rightarrow$ 保留不动。

$$\Phi_{\text{bin}}(\mathbf{P}, \mathbf{B})[x, y] = \begin{cases} \text{mode}(\mathbf{P}[B_C]), & (x, y) \in C, \text{surrounded}(C), r_C > 0.5 \\ \mathbf{P}[x, y], & \text{otherwise} \end{cases} \quad (4)$$

式中 $\mathbf{B} \in \{0, 1\}^{H \times W}$ 为二分模型输出（1= 水域）， $r_C = |\{(u, v) \in C : \mathbf{B}[u, v] = 1\}|/|C|$ 。

关键约束： Φ_{bin} 只处理水中岸（被水域完全包围的岸连通域），不触碰与外界岸相连的边界区域。这确保二分模型不会越权修改岸线——拓扑步骤已经确定了”哪里是岸”的结构框架，二分模型只在框架内的”争议区域”做出像素级判决。

2.5 设计原则

三步流水线遵循四条核心设计原则：

(1) 拓扑 $\rightarrow$ 几何 $\rightarrow$ 语义的解耦层次。 Φ_{shore} 处理全局连通性（拓扑层次）， Φ_{water} 处理局部碎片的几何形态（面积 + 包围关系）， Φ_{bin} 处理残留像素的语义歧义（岸 vs 水域的二分类）。这种分层设计确保每个步骤有明确的处理边界，避免单一操作同时应对多种噪声导致的顾此失彼。

(2) 分割是唯一真相源。后处理只修正分割掩码中的结构级和像素级错误，不改变分割模型正确判别的区域。所有步骤的决策均基于原始分割掩码的信息（连通域、类别分布、面积），后处理是分割的补充而非替代。

(3) 不可交换的执行顺序。 Φ_{shore} 必须最先执行：若先执行 Φ_{water} ，大量孤立假水域中的岸像素会被误判为“被水域包围的碎片”而错误填充。 Φ_{water} 必须在 Φ_{bin} 之前： Φ_{bin} 处理残留，若先执行会使二分模型面对已被 Φ_{water} 修正前的更多噪声。 Φ_{bin} 在最后，作为语义防线不再产生新的结构级变化。

(4) 二分模型的信息优势。四分类器需要同时区分岸/水/水草/藻类，在岸-水边界上的判别能力受四类联合分布影响。二分类器仅需区分岸/水域，参数容量集中在单一任务上，在该子任务上具有更高的准确率。 Φ_{bin} 利用这种信息优势，在四分类器已确定“这是被水域包围的像素”的结构约束下，引入更强的二元判别器做最终裁决。

3 实验

3.1 实验设置

数据集。实验使用 54 张 DJI 无人机可见光影像（DNG 格式），拍摄高度约 120 m，地面采样距离（GSD）约 5 cm/px。每张图像进行了像素级 4 类语义标注（岸/水/水生植物/藻类），标注人员使用多边形标注工具在原始分辨率下完成。部分图像包含悬空树冠遮挡区域（标注为忽略像素 255），评估时排除这些区域。

分割模型。4 类语义分割采用 DeepLabV3+ 架构，backbone 为 ConvNeXt-Tiny（ImageNet-1K 预训练），约 36.7M 参数。岸水二分模型采用相同架构，约 35.8M 参数，训练数据由 4 类标签自动映射生成（岸 $\rightarrow$ 0，水域 $\rightarrow$ 1），mIoU 达 0.977。模型训练时输入缩放至 512 $\times$ 512，推理时保持原始分辨率，对非 32 倍数的尺寸进行反射填充后将预测裁剪回原始尺寸。

评价指标。采用语义分割标准指标：平均交并比（ $\text{mIoU} = \frac{1}{|C|} \sum_{c \in C} \text{IoU}_c$ ）和各类别 IoU。计算时排除标注为“忽略”的像素，确保评估不受标注不确定性影响。

消融实验设计。为验证每个后处理步骤的独立贡献，设计 4 种递进配置：Config 1（Baseline）——原始分割输出；Config 2（+Step1）——仅启用 Φ_{shore} ；Config 3（+Step1+2）——启用 $\Phi_{\text{shore}} \circ \Phi_{\text{water}}$ ；Config 4（Full）——全开 $\Phi_{\text{bin}} \circ \Phi_{\text{water}} \circ \Phi_{\text{shore}}$ 。每个配置在全部标注数据上运行推理，计算 mIoU 和各类别 IoU 的变化量 Δ 。

3.2 消融实验结果

表 1 展示了 4 种配置在 54 张标注数据（含训练集和验证集）上的 mIoU 和各类 IoU。由于在全部数据上评估（包含模型尚未充分学习的困难样本），绝对 mIoU 值（0.7213）低于仅使用验证集的最佳结果（ ~ 0.81 ）。消融实验的核心价值在于相对变化量 Δ 。

表 1: 消融实验结果（54 张全量数据）


配置	mIoU	Shore	Water	Plant	Algae
全量 54 张（含 48 张零修改）					
Baseline	0.7213	0.8450	0.8588	0.6502	0.5849
Full	0.7237	0.8899	0.8587	0.6507	0.5849
Δ	+0.0024	+0.0449	-0.0001	+0.0005	0.0000
后处理有效果的 6 张					
Baseline	0.6324	0.6085	0.8859	0.7697	0.1443
Full	0.6541	0.7228	0.8844	0.7738	0.1443
Δ	+0.0217	+0.1143	-0.0015	+0.0041	0.0000

表 1 上半部分为全量 54 张数据的平均结果，下半部分为后处理实际产生像素修改的 6 张图像上的平均结果。

全量数据上的 Δ 被严重稀释。54 张图像中，48 张（88.9%）的后处理改变像素数为 0——这恰恰证明了后处理的”安静”特性：正确分割的区域不会被误修改。但也因此，全量平均的 mIoU 提升仅 +0.0024（+0.33%），无法反映后处理在真正需要的场景中的实际价值。


在有效果的图像上， Δ 具有实质性意义。6 张有像素修改的图像上，mIoU 从 0.6324 提升至 0.6541（**+0.0217**，**+3.4%**）。其中 Shore IoU 的提升最为显著：从 0.6085 提升至 0.7228（**+0.1143**，**+18.8%**），直接验证了二分模型（mIoU 0.977）相较于四类模型（Shore IoU 0.6085）在岸/水二分类上的信息优势。Water IoU 的微弱下降（-0.0015）和 Aquatic Plant IoU 的小幅上升（+0.0041）表明少数类投票机制的定向修正效果：正确地将误判为岸的像素恢复为原有的非岸类别，而非简单全部归为水。

图 1 以柱状图形式展示了消融实验的核心结果。



(a) mIoU 双组对比（全量 vs 有效果）

(b) Shore IoU 提升特写



(c) 各类别 IoU 双组对比

图 1: 消融实验结果可视化

3.3 定性分析

3.3.1 完整 DNG 正射校正图上的效果

图 2 展示了后处理在 2048×2048 完整正射校正图上的效果。DJI_0144 中，四类分割模型在连续岸区域的内部错误地标记了多处假水域（1675 px），这些假水域被真实岸像素完全包围，与主体水域互不连通。 Φ_{shore} 通过连通域分析识别出它们不属于主体水域，全部修正为岸。Step 2 和 Step 3 在此图上未触发——岸线和水域内部的分割已足够准确。值得注意的是，在全部 20 张干净 DNG 图像中，18 张的后处理改变像素数为 0，表明后处理具有良好的“安静”特性：仅在分割模型产生明确的结构性错误时才介入。





图 2: 完整 DNG 正射校正图上的 Step 1 效果。DJI_0144 (1675 px 修正): 四类模型在连续岸区域内部产生孤立假水域 (中图, 岸中的蓝色斑块), Φ_{shore} 通过保留最大水域连通域将其修正为岸 (右图)。

3.3.2 训练裁剪图上的效果

图 3 展示了训练裁剪图上 Step 2 和 Step 3 的独立效果。

DJI_0160(2) (Step 2, 711 px)。四类模型将一片水生植物叶片的靠图像边缘一侧误判为岸 (0), 该误判连通域被水域完全包围、面积仅 711 px², 满足 Φ_{water} 的填充条件。多数类投票机制检测到该碎片周围像素以水生植物 (2) 为主, 因此将其填充为水生植物而非默认的水类别。这一案例体现了多数类投票相较于固定类别填充的优势: 它利用局部上下文做出了更细粒度的类别选择。

DJI_0149 (Step 3, 32947 px)。该图左下角约 1/24 区域为悬空树冠, 标注时标记为忽略 (255), 不参与训练损失计算。因此四类模型在此区域没有学到一致的类别映射, 输出呈现混合状态 (岸/水/水草/藻类混杂)。 Φ_{bin} 针对其中被误判为岸 (0) 的像素, 使用二分模型逐像素判断其是否为水域: 二分模型将这些树冠区域正确识别为水域, 将其修正为水 (1), 共修正 32947 px, mIoU 从 0.4082 提升至 0.5443 (+0.1361)。需要指出, Φ_{bin} 仅修正了树冠区被判为岸的像素——被判为其他类别的像素 (如藻类、水草) 不在其处理范围内。这一案例展示了二分模型的明确价值: 当四分类器因标注不确定性 (忽略标签) 在遮挡区域产生混乱输出时, 二分模型能够以更高的岸/水判别精度做出修正。



(a) DJI_0160(2) (Step 2 水拓扑修复, 711 px) (b) DJI_0149 (Step 3 二分修正, 32947 px)

图 3: 训练裁剪图上的后处理效果。(左) 原始图像; (中) 原始分割; (右) 后处理后

3.4 计算开销

三步后处理的计算开销如表 2 所示。 Φ_{shore} 和 Φ_{water} 为纯 CPU 连通域分析，耗时不到 1 ms。 Φ_{bin} 的主要开销来自二分模型的一次 GPU 前向传播 (~ 45 ms)，但该步骤与 4 类分割模型共享 GPU 上下文，无需额外显存分配。CPU 部分均为线性时间复杂度，不随图像分辨率增长而产生瓶颈。

表 2: 后处理计算开销 (54 张图平均, 混合分辨率)

步骤	耗时 (ms/帧)	主要操作
Φ_{shore} (CPU)	< 1	连通域标记
Φ_{water} (CPU)	< 1	连通域标记 + 膨胀
Φ_{bin} (GPU)	~ 45	二分模型前向传播
Φ_{bin} (CPU)	< 1	连通域标记 + 投票
合计	~ 46	—

3.5 讨论

Step 3 的效果与数据难度相关。 Φ_{bin} 的效果集中在四分类器对岸/水边界出现系统性误判的图像上。如 DJI_0149 中，悬空树冠导致四类模型将水域误判为岸，而二分模型 (mIoU 0.977) 穿透树冠纹理干扰，成功将误判区域修正为水域。在岸线清晰、四分类器判别准确度较高的图像上， Φ_{bin} 的修正像素数趋近于零。这一观察提示：二分模型修正的边际价值随四类分割模型 Shore IoU 的提升而递减——当四类模型的岸类判别足够准确时， Φ_{bin} 可被省略以减少计算开销。

局限性。当前 Φ_{water} 的面积阈值 $\tau_{\text{max}} = 5000 \text{ px}^2$ 为固定经验值，在更高分辨率的图像上可能需要调整。此外，二分模型的训练依赖于与四类模型相同的标注数据，增加了系统的训练成本。

4 结论

本文针对无人机影像藻类分割中分割模型输出存在的三类典型噪点——孤立假水体、水中假岸碎片和岸边语义混淆——提出了一种三步拓扑后处理流水线。该方法在不重新训练分割模型的前提下，通过岸拓扑修复 (Φ_{shore})、水拓扑修复 (Φ_{water}) 和二分语义修正 (Φ_{bin}) 三个步骤逐级提升分割质量。

在 54 张标注数据上的消融实验表明，全开配置相较原始分割提升 mIoU +0.0024，其中 Shore IoU 提升 +0.0449 (+5.3%)。 Φ_{bin} (二分模型修正) 是贡献最大的步骤，验证了“二分类信息优势”在像素级修正中的有效性。定性分析进一步显示，后处理在完

整 DNG 正射校正图和含困难样本的裁剪图上均能有效消除噪点，同时保持对正确分割区域的零干扰。

本文的核心设计原则——”拓扑负责结构，语义负责像素判别，两者解耦且互不越界”——不仅适用于藻类分割场景，也可推广至其他需要后处理的分割任务（如河道提取、海岸线检测等）。未来工作包括：（1）将面积阈值 $\tau_{\max}$ 替换为自适应估计方法；（2）探索将后处理嵌入分割模型训练过程实现端到端学习；（3）在更大规模、更多样化的数据集上验证方法的泛化能力。

Staged Topological Post-Processing: A Lightweight Method for Improving Algae Segmentation Quality in UAV Imagery

WU Tianyu¹, LIU Junhui¹, HE Yiran¹, QIAO Zige¹

¹School of Artificial Intelligence and Automation, Huazhong University of Science and Technology, Wuhan 430074, China

Abstract: Semantic segmentation of UAV visible-light imagery for algae monitoring faces three typical noise patterns: isolated false water bodies, false shore fragments inside water regions, and shoreline pixel misclassification. This paper proposes a three-stage topological post-processing pipeline that improves segmentation quality without retraining the segmentation model. Stage 1 eliminates isolated water bodies through connected-component analysis (shore topology repair). Stage 2 fills small shore fragments (≤ 5000 px²) fully surrounded by water using majority-class voting (water topology repair). Stage 3 employs a binary shore/water classifier (mIoU 0.977) for pixel-level semantic correction of residual in-water shore pixels. Ablation experiments on 54 annotated UAV images demonstrate that post-processing improves Shore IoU by +5.3% (0.8450 $\rightarrow$ 0.8899) globally and +18.8% (0.6085 $\rightarrow$ 0.7228) on affected images, with an overall mIoU gain of +3.4% on images where post-processing is activated. The method follows the design principle of “topology governs structure, semantics govern pixel discrimination” and generalizes to other segmentation-based water analysis tasks.

Keywords: semantic segmentation post-processing; topology repair; connected component analysis; algae monitoring; UAV imagery

致谢

感谢华中科技大学人工智能与自动化学院提供的无人机影像数据和标注支持。感谢导师左峥嵘教授和王岳环教授的指导。

参考文献

- [1] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 801–818, 2018.

- [2] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, and Saining Xie. A convnet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11976–11986, 2022.
- [3] Connor Shorten and Taghi M. Khoshgoftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1):1–48, 2019.
- [4] Philipp Krähenbühl and Vladlen Koltun. Efficient inference in fully connected crfs with gaussian edge potentials. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 109–117, 2011.